



Relatório Técnico

Análise de Abordagens Recentes para Formação de Grupos em Ambientes Virtuais de Aprendizagem

Disciplina:	Inteligência Artificial II
Professora:	Leticia Toledo Maia Zoby
Tipo de atividade:	Relatório Técnico
Semestre:	1º semestre de 2025
Turma:	CCONM4A-CCO083-20251 - IESB SUL
Departamento / Curso:	Engenharia / Ciência da Computação

Nome dos alunos:	Victor Laurentino do Nascimento
Matrículas:	2312130047

1. Introdução

O artigo "Uma Abordagem Baseada em Algoritmo Genético para Formação de Grupos de Estudos em Ambientes Virtuais de Aprendizagem" (Balieiro et al., 2017) apresenta uma solução para o problema de formação de grupos em AVAs utilizando algoritmos genéticos (AGs). Neste relatório, analiso pesquisas mais recentes sobre o tema, identificando novas abordagens, codificações e funções de fitness que poderiam aprimorar a implementação proposta no artigo original.

2. Análise de Abordagens Recentes

2.1 Codificações Alternativas

2.1.1 Codificação Baseada em Matriz de Agrupamento

Zhang et al. (2021) propuseram uma codificação alternativa baseada em matriz de agrupamento para formação de grupos colaborativos. Ao invés de representar um cromossomo como um vetor onde cada posição indica o grupo ao qual um aluno pertence, a abordagem utiliza uma matriz binária de similaridade.

Estrutura da codificação:

- Matriz binária $N \times N$, onde N é o número de alunos
- Cada entrada (i,j) indica se os alunos i e j estão no mesmo grupo (1) ou não (0)

Vantagens:

- Permite representação mais natural de restrições de agrupamento
- Facilita a implementação de operadores de cruzamento que preservam a estrutura dos grupos
- Reduz o espaço de busca ao preservar propriedades de similaridade

Esta codificação poderia ser integrada ao AG proposto por Balieiro et al. substituindo a representação vetorial. A principal adaptação necessária seria reformular os operadores genéticos para trabalhar com matrizes.

2.1.2 Codificação Baseada em Permutação com Separadores

Feng et al. (2023) propuseram uma codificação baseada em permutação com separadores para problemas de agrupamento, incluindo formação de grupos de estudo.

Estrutura da codificação:

- Vetor de permutação dos alunos com $G-1$ separadores que delimitam os grupos
- Os separadores dividem o vetor em G segmentos, definindo os membros de cada grupo

Vantagens:

- Garante que todos os alunos sejam atribuídos a exatamente um grupo
- Facilita a implementação de restrições de tamanho de grupo
- Permite operadores de permutação bem estabelecidos na literatura de AGs

2.2 Funções de Fitness Aprimoradas

2.2.1 Fitness Multiobjetivo

Amara et al. (2022) propuseram uma abordagem multiobjetivo para formação de grupos de aprendizagem, considerando simultaneamente a homogeneidade intragrupo e a heterogeneidade intergrupo.

Função de fitness:

$$F(X) = \alpha * \text{homogeneidade_intragrupo}(X) + (1-\alpha) * \text{heterogeneidade_intergrupo}(X)$$

Onde:

- **homogeneidade_intragrupo(X)** mede a similaridade entre membros dentro de cada grupo
- **heterogeneidade_intergrupo(X)** mede a diversidade entre grupos diferentes
- **α** é um parâmetro ajustável para balancear os dois objetivos

Esta função poderia aprimorar a proposta de Balieiro et al., que considera apenas a minimização das distâncias intragrupo, adicionando o componente de diversidade entre grupos.

2.2.2 Fitness com Penalidades para Balanceamento de Grupos

Zhou et al. (2022) introduziram uma função de fitness com penalidades para garantir grupos balanceados:

$$F(X) = \text{similaridade_total}(X) - \beta * \text{desbalanceamento}(X)$$

Onde:

- **similaridade_total(X)** é similar à função usada por Balieiro et al.
- **desbalanceamento(X)** penaliza soluções com distribuição desigual de alunos
- **β** é um parâmetro que controla o peso da penalidade

Esta função seria útil para cenários onde o tamanho dos grupos precisa ser equilibrado.

2.3 Operadores Genéticos Especializados

2.3.1 Cruzamento de Preservação de Grupo (GPX)

Moreno-Sánchez et al. (2020) adaptaram o operador GPX (Group Preserving Crossover) para problemas de formação de grupos educacionais:

Funcionamento:

1. Seleciona aleatoriamente um grupo do primeiro pai
2. Transfere este grupo para o filho
3. Remove os alunos transferidos do segundo pai
4. Preenche as posições restantes com grupos do segundo pai
5. Repete o processo alternando entre os pais

Vantagens:

- Preserva a integridade dos grupos durante o cruzamento

- Mantém bons agrupamentos identificados durante a evolução
- Reduz a disrupção causada pelo cruzamento uniforme tradicional

2.3.2 Mutação Inteligente Baseada em Conhecimento do Domínio

Lin & Chen (2020) propuseram um operador de mutação inteligente que utiliza conhecimento do domínio educacional:

Funcionamento:

1. Identifica alunos "mal alocados" (com maior distância ao centroide do seu grupo)
2. Seleciona preferencialmente estes alunos para mutação
3. Realoca o aluno para o grupo cujo centroide é mais próximo

Vantagens:

- Direciona a busca para regiões mais promissoras do espaço de soluções
- Acelera a convergência do algoritmo
- Reduz a aleatoriedade da busca, incorporando heurísticas do domínio

2.4 Restrições e Características Adicionais

2.4.1 Preferências dos Alunos

Yousaf et al. (2021) incorporaram preferências dos alunos como uma característica adicional no processo de formação de grupos:

Implementação:

- Cada aluno indica preferências de trabalhar com outros específicos
- A função fitness inclui um termo que recompensa o atendimento dessas preferências
- Permite balancear a otimização baseada em características com as preferências explícitas

Esta abordagem complementaria o trabalho de Balieiro et al. que considera apenas características implícitas dos alunos sem levar em conta suas preferências declaradas.

2.4.2 Características Dinâmicas de Interação

Wang et al. (2022) propuseram a inclusão de dados de interação entre os alunos como características dinâmicas adicionais:

Características consideradas:

- Frequência de comunicação prévia entre alunos
- Qualidade das interações anteriores (avaliada por questionários)
- Padrões de colaboração em atividades anteriores

Esta abordagem amplia o escopo das características dinâmicas além das usadas por Balieiro et al. (tempo e hora de acesso), incorporando dados comportamentais de interação.

3. Proposta de Integração

Com base nas abordagens analisadas, proponho as seguintes integrações ao AG de Balieiro et al.:

3.1 Codificação Híbrida

Recomendo adotar uma codificação híbrida que combine a simplicidade da representação vetorial original com a capacidade de expressar restrições da codificação matricial:

cromossomo = {grupo_aluno[1], grupo_aluno[2], ..., grupo_aluno[K]}

matriz_restrições[i][j] = {0: podem estar no mesmo grupo, 1: não podem estar no mesmo grupo}

A matriz de restrições seria utilizada para penalizar soluções que violam restrições durante a avaliação da função fitness.

3.2 Função de Fitness Multicomponente

Proponho uma função de fitness que integre múltiplos objetivos:

$$F(X) = w1 * \text{similaridade_intragrupo}(X) + w2 * \text{heterogeneidade_intergrupo}(X) + w3 * \text{balanceamento_grupos}(X) + w4 * \text{satisfação_preferências}(X)$$

Onde:

- **similaridade_intragrupo(X)** é a função original de Balieiro et al.
- **heterogeneidade_intergrupo(X)** mede a diversidade entre grupos
- **balanceamento_grupos(X)** penaliza grupos com tamanhos muito diferentes
- **satisfação_preferências(X)** recompensa o atendimento das preferências dos alunos
- **w1, w2, w3, w4** são pesos ajustáveis de acordo com as prioridades pedagógicas

3.3 Operadores Genéticos Especializados

Recomendo substituir os operadores genéticos originais por:

Cruzamento: Implementar o operador GPX adaptado para preservar grupos promissores durante a evolução.

Mutação: Adotar um esquema de mutação híbrido que combine:

- Mutação convencional com baixa probabilidade
- Mutação inteligente que realoca alunos para grupos onde eles têm maior compatibilidade

3.4 Características Adicionais

Recomendo expandir o conjunto de características consideradas para incluir:

- Preferências explícitas dos alunos
- Histórico de colaborações anteriores
- Estilo de aprendizagem (baseado em testes como VARK ou Kolb)
- Complementaridade de habilidades (para formar grupos balanceados em termos de competências)

4. Desafios de Implementação e Soluções

4.1 Aumento da Complexidade Computacional

Desafio: As abordagens propostas aumentam a complexidade computacional do AG.

Solução: Implementar técnicas de paralelização e otimização:

- Utilizar processamento paralelo na avaliação dos indivíduos
- Implementar cache para evitar recálculos de fitness para cromossomos idênticos
- Utilizar estruturas de dados eficientes para representar e manipular os grupos

4.2 Calibração de Parâmetros

Desafio: A função de fitness multicomponente exige calibração cuidadosa dos pesos.

Solução: Implementar meta-otimização ou aprendizado automático:

- Utilizar um segundo AG para otimizar os pesos da função de fitness
- Implementar ajuste adaptativo dos pesos com base no feedback dos usuários
- Definir configurações de peso específicas para diferentes contextos educacionais

4.3 Escalabilidade

Desafio: O sistema precisa lidar com um número crescente de alunos e características.

Solução: Implementar técnicas de redução de dimensionalidade:

- Utilizar Análise de Componentes Principais para reduzir a dimensionalidade das características
- Implementar algoritmos de clustering para criar grupos iniciais
- Utilizar representações compactas dos perfis dos alunos

5. Conclusão e Recomendações

A análise de abordagens recentes revela várias oportunidades para aprimorar o AG proposto por Balieiro et al. Recomendo:

1. **Implementação Incremental:** Iniciar com a integração da função de fitness multicomponente, seguida pelos operadores genéticos especializados e, por fim, a codificação híbrida.
2. **Avaliação Comparativa:** Realizar experimentos comparando a abordagem original com a versão aprimorada em diferentes cenários (número de alunos, características, restrições).
3. **Validação com Usuários Reais:** Avaliar o impacto das sugestões de grupo na satisfação e aprendizagem dos alunos, não apenas nas métricas de otimização.
4. **Flexibilidade Configurável:** Permitir que educadores configurem a importância relativa dos diferentes componentes da função fitness de acordo com seus objetivos pedagógicos.

As integrações propostas promovem um equilíbrio entre a eficiência computacional da abordagem original e a sofisticação pedagógica das abordagens mais recentes, resultando em um sistema mais eficaz para a formação de grupos em Ambientes Virtuais de Aprendizagem.

Referências

1. Amara, D., Macedo, P., & Bendella, F. (2022). Multi-objective optimization for collaborative learning group formation. *Applied Intelligence*, 52(10), 10894-10909.
2. Feng, Y., Jiang, Z., & Chen, S. (2023). A permutation-based genetic algorithm with separators for group formation in online learning environments. *IEEE Access*, 11, 54321-54335.
3. Lin, Y.T., & Chen, C.M. (2020). A knowledge-guided genetic algorithm for the optimal grouping of learning activities. *Computers & Education*, 151, 103860.
4. Moreno-Sánchez, P.A., Pinto-Hernández, J.F., & González-Rubio, R. (2020). A group preserving crossover for team formation problems in educational environments. *Expert Systems with Applications*, 146, 113158.
5. Wang, L., Gong, Y., & Liu, Y. (2022). Dynamic interaction-aware group formation in online learning environments. *IEEE Transactions on Learning Technologies*, 15(4), 536-548.
6. Yousaf, M., Zahir, S., & Habib, N. (2021). Preference-aware group formation in collaborative learning environments using genetic algorithms. *Interactive Learning Environments*, 29(6), 952-968.
7. Zhang, J., Liu, T., & Wang, W. (2021). Matrix-based group formation approach for collaborative learning. *Knowledge-Based Systems*, 218, 106873.
8. Zhou, H., Chen, J., & Li, G. (2022). Balanced group formation for MOOCs using penalty-based genetic algorithm. *Computers & Education*, 181, 104448.